머신러닝 기술을 이용한 개인의 특성에 따른 패션 추천

이재호(B811141, 컴퓨터공학전공) 1 지도교수: 송하윤(컴퓨터공학전공) 2

홍익대학교

Introduction

본 연구의 목적은 머신러닝 기술을 활용하여, 개인의 특성(예: 성별, 나이, 직업, 선호 스타일 등)에 맞게 패션을 추천해 주는 인공지능 모델을 구축하는 것이다. 본 연구에서는 머신러닝 기술 중 Logistic Regression, AdaBoost Classifier, Gradient Boosting Classifier을 사용하였으며, 참가자들의 설문 조사 dataset을 가지고 그 결과를 확인하였다. 이때 설문 조사 dataset은 참가자들에게 패션 이미지를 보여주고 해당 이미지에 대한 평가와 참가자들의 정보를 담고 있는 dataset이다. 끝으로, 전체적인 과정은 '1) 데이터 전처리, 2) 모델링, 3) 결과'로 정리하였다.

1. 데이터 전처리

raw dataset에서 이미지 dataset 및 참가자 dataset 추출 및 가공하는 것을 목적으로 하였다.

| 4 | Α | В | С | D | Е | F | G | Н | I | J | K | L | М | N |
|----|--------|---------------------------------|------|----------------|--------|----|------|------|-------|-------|-----|-----|--------|--------|
| 1 | E_id 🕌 | imgName | era | style | gend 🕌 | Q1 | Q2 🕌 | Q3 🕌 | Q41 🕌 | Q41[_ | Q41 | Q41 | Q420 🗼 | Q420 🖵 |
| 2 | 1 | W_15268_50_ivy_M.jpg | 1950 | ivy | М | 4 | 1 | 1 | 3 | 2 | 2 | 2 | 0 | 2 |
| 3 | 2 | W_16543_50_ivy_M.jpg | 1950 | ivy | М | 2 | 1 | 2 | 2 | 2 | 2 | 2 | 0 | 0 |
| 4 | 3 | W_17697_50_ivy_M.jpg | 1950 | ivy | М | 3 | 1 | 1 | 2 | 2 | 2 | 2 | 0 | 2 |
| 5 | 4 | W_00485_60_mods_M.jpg | 1960 | mods | М | 4 | 1 | 1 | 2 | 2 | 2 | 2 | 1 | 0 |
| 6 | 5 | W_06723_60_mods_M.jpg | 1960 | mods | М | 3 | 1 | 5 | 3 | 1 | 1 | 1 | 0 | 0 |
| 7 | 6 | W_15212_60_mods_M.jpg | 1960 | mods | М | 2 | 1 | 2 | 1 | 1 | 1 | 1 | 0 | 0 |
| 8 | 7 | W_01612_70_hippie_M.jpg | 1970 | hippie | М | 1 | 1 | 5 | 1 | 1 | 1 | 1 | 0 | 0 |
| 9 | 8 | W_03007_70_hippie_M.jpg | 1970 | hippie | М | 4 | 1 | 5 | 2 | 2 | 2 | 2 | 0 | 2 |
| 10 | 9 | W_06563_70_hippie_M.jpg | 1970 | hippie | М | 1 | 2 | 4 | 3 | 2 | 1 | 2 | 0 | 0 |
| 11 | 10 | W_15371_80_bold_M.jpg | 1980 | bold | М | 2 | 1 | 1 | 1 | 1 | 1 | 1 | 0 | 0 |
| 12 | 11 | W_16068_80_bold_M.jpg | 1980 | bold | М | 3 | 1 | 1 | 2 | 1 | 1 | 1 | 1 | 0 |
| 13 | 12 | W_17957_80_bold_M.jpg | 1980 | bold | М | 3 | 1 | 2 | 2 | 1 | 1 | 1 | 0 | 2 |
| 14 | 13 | W_02785_90_hiphop_M.jpg | 1990 | hiphop | М | 1 | 2 | 5 | 2 | 2 | 1 | 1 | 0 | 2 |
| 15 | 14 | W_07347_90_hiphop_M.jpg | 1990 | hiphop | М | 1 | 1 | 5 | 1 | 1 | 1 | 1 | 0 | 0 |
| 16 | 15 | W_16892_90_hiphop_M.jpg | 1990 | hiphop | М | 1 | 1 | 5 | 2 | 1 | 1 | 1 | 0 | 0 |
| 17 | 16 | W_16797_00_metrosexual_M.jpg | 2000 | metrosexual | М | 1 | 2 | 5 | 2 | 1 | 1 | 1 | 0 | 0 |
| 18 | 17 | W_17324_00_metrosexual_M.jpg | 2000 | metrosexual | М | 1 | 3 | 5 | 1 | 1 | 1 | 1 | 0 | 0 |
| 19 | 18 | W_17881_00_metrosexual_M.jpg | 2000 | metrosexual | М | 2 | 2 | 5 | 1 | 2 | 1 | 1 | 0 | 2 |
| 20 | 19 | W_04527_10_sportivecasual_M.jpg | 2010 | sportivecasual | М | 4 | 1 | 5 | 3 | 2 | 2 | 1 | 0 | 0 |
| 21 | 20 | W_04564_10_sportivecasual_M.jpg | 2010 | sportivecasual | М | 2 | 3 | 5 | 3 | 2 | 1 | 1 | 0 | 0 |
| 22 | 21 | W_06193_10_sportivecasual_M.jpg | 2010 | sportivecasual | М | 4 | 2 | 5 | 3 | 2 | 2 | 2 | 0 | 0 |

Figure 1. raw dataset (일부 rows, columns)



Figure 2. 이미지 샘플(W_08958_19_genderless_W)

1-1. 이미지 dataset 추출 및 가공

raw dataset에서 이미지에 대한 정보로 추출할 만한 요소로 참가자들의 해당 이미지에 대한 평가를 꼽았다. 이미지에 대한 요소로 '계절감, 핏, 색상, 색감, 분위기, 기타 스타일' 등이 있으며, 본 연구에서는 각각의 요소에 따라 가장 많이 선택된 특징을 해당 이미지의 특성으로 입력하였다(예를 들어 3명 중 2명이 봄 의상, 1명이 여름 의상이라고 응답했다면, 해당 의상의 계절감은 봄으로 입력된다.). 그리하여 이미지의 정보를 데이터화하여 이를 추출하였다.

1-1-A. 이미지 dataset 추출 및 가공 코드

Figure 3. 과정1. raw dataset 추출과 column명 리스트 생성

```
r i in range(len(research_dataset)):
imgName = research_dataset.loc[i,'imgName']
if imgName not in img_dict.keys():
 img_dict[imgName]=[0 for _ in range(23)] # index 0~21: answer , 22:count
 f imgName not in q3_dict.keys():
 q3_dict[imgName]=[0 for _ in range(9)] # index 0~7: answer, 8:count
q2_to_q4 = research_dataset.loc[i][6:28] #q2_to_q4는 Q2~Q4216에 대한 답
img_dict[imgName][-1]+=1
q3_dict[imgName][-1]+=1
for x in range(22):
   select = q2_to_q4[1] #1 ~ 8
   q3_dict[imgName][select-1]+=1
   select = q2_to_q4[x] #1 or 2 or 3
   if select == 1: #봄/가을 이면 2로
     select = 2
   if select == 2: #여름이면 1로
    select = 1
   img_dict[imgName][x]+=select
   select = q2_to_q4[x] #1 or 2 or 3
   img_dict[imgName][x]+=select
   select = q2_to_q4[x] #1 or 2
   select -= 1
   img_dict[imgName][x]+=select
   select = q2_to_q4[x] #0 or not0
   if select != 0: #only 0 or 1
     select = 1
   img_dict[imgName][x]+=select
```

Figure 4. 과정2. research dataset으로 부터 정보 추출

```
for key,values in img_dict.items():
    for i in range(22):
        if i==1: #about Q3
             num = q3_dict[key].index(max(q3_dict[key][:8]))
             num += 1 #1~8: work~etc.
             img_dict[key][1]=num

else:
             avg = values[i]/values[-1]
            img_dict[key][i]=avg

temp_image=temp_image.set_index('imgName')
```

Figure 5. 과정3. Q3(선호도) column에 대한 정보 추출

```
r k,values in img_dict.items():
 if values[0] < 1.5:
  temp_image.loc[k,'season']='summer'
elif values[0] > 2.5:
  temp_image.loc[k,'season']='winter'
  temp_image.loc[k,'season']='spring_fall'
#for situation
s_list=[0,'work','date','event','social_gathering','daily','leisure','vacation','etc']
temp_image.loc[k,'situation']=s_list[values[1]]
if values[2] < 1.5:
  temp_image.loc[k,'fit']='loose_fit'
elif values[2] > 1.5:
  temp_image.loc[k,'fit']='tight_fit'
  temp_image.loc[k,'fit']='svitable_fit'
if values[3] < 0.5:
 temp_image.loc[k,'dark_bright']='dark'
  temp_image.loc[k,'dark_bright']='bright'
 if values[4] < 0.5:
  temp_image.loc[k,'cold_warm']='cold'
  temp_image.loc[k,'cold_warm']='warm'
if values[5] < 0.5:
 temp_image.loc[k,'heavy_light']='heavy'
  temp_image.loc[k,'heavy_light']='light'
s_list=[0,0,0,0,0,0,'cool','urban','trandy','stylish','neat','fancy',
for i in range(6,22):
  if values[i] < 0.5:</pre>
    temp_image.loc[k,s_list[i]]='not_'+s_list[i]
    temp_image.loc[k,s_list[i]]=s_list[i]
```

Figure 6. 과정4. 이미지에 대한 정보를 기반으로 새로운 dataset 생성

1-1-B. 이미지 dataset 추출 및 가공 결과

| imgName | era | style | gender | count | season | situation | fit | dark_bright | cold_warm | heavy_light | cool | urban | trandy |
|-----------|-----|-------------|--------|-------|---------------|-------------|--------------|-------------|-----------|-------------|----------|-----------|------------|
| W_00002_ | | 60 mods | M | | 1 summer | work | tight_fit | bright | warm | light | not_cool | not_urban | not_trandy |
| W_00003_! | 19 | 50 ivy | М | | 4 spring_fall | work | tight_fit | dark | cold | heavy | cool | urban | not_trandy |
| W_00004_! | 19 | 50 ivy | М | | 1 summer | work | tight_fit | bright | warm | light | not_cool | urban | trandy |
| W_00005_i | 19 | 60 mods | М | | 2 spring_fall | social_gath | suitable_fit | bright | warm | light | cool | urban | not_trandy |
| W_00007_i | 19 | 60 mods | М | | 4 summer | event | tight_fit | bright | warm | light | not_cool | urban | trandy |
| W_00008_ | 19 | 19 normcore | М | | 1 winter | daily | tight_fit | bright | warm | light | cool | not_urban | not_trandy |
| W_00010_{ | 19 | 50 ivy | М | | 3 spring_fall | work | tight_fit | dark | cold | heavy | cool | urban | not_trandy |
| W_00011_ | 19 | 80 bold | М | | 1 summer | social_gath | loose_fit | dark | cold | heavy | not_cool | not_urban | not_trandy |
| W_00012_{ | 19 | 50 ivy | М | | 3 summer | daily | tight_fit | dark | cold | heavy | not_cool | not_urban | not_trandy |
| W_00013_ | 19 | 19 normcore | М | | 1 summer | daily | tight_fit | dark | warm | light | not_cool | urban | not_trandy |
| W_00014_(| 19 | 60 mods | М | | 1 summer | event | tight_fit | dark | cold | heavy | not_cool | urban | trandy |
| W_00015_! | 19 | 50 ivy | М | | 6 summer | work | tight_fit | bright | warm | light | cool | urban | not_trandy |
| W_00016_{ | 19 | 50 ivy | М | | 3 summer | work | tight_fit | bright | warm | light | not_cool | not_urban | not_trandy |
| W_00017_I | 19 | 60 mods | М | | 1 summer | work | tight_fit | dark | warm | heavy | cool | not_urban | not_trandy |
| W_00018_i | 19 | 60 mods | М | | 2 spring_fall | event | tight_fit | dark | warm | heavy | cool | urban | trandy |
| W_00019_ | 19 | 19 normcore | М | | 1 summer | daily | tight_fit | bright | warm | heavy | cool | urban | not_trandy |
| W_00020_I | 19 | 60 mods | М | | 2 summer | work | tight_fit | dark | warm | light | cool | urban | not_trandy |

Figure 7. 추출한 이미지 dataset (일부 rows, columns)

1-2. 참가자 dataset 추출 및 가공

raw dataset에서 참가자들의 정보를 담고 있는 column을 가지고 참가자 dataset으로 추출하였다. 이때 '성별, 나이, 직업, 선호 스타일 등'을 특성으로 꼽았다.

1-2-A. 참가자 dataset 추출 및 가공 코드

```
user_dict = {}
 for i in range(len(research_dataset)):
  R_id = research_dataset.loc[i,'R_id']
  #해당 R_id를 갖는 key가 없으면 추가
  if R_id not in user_dict.keys():
   user_dict[R_id]=[0 for _ in range(10)] # 0 ~ 9 : r_gender ~ r_style5
    gender_to_style5 = research_dataset.loc[i][30:] #gender~style5에 대한 답
    for x in range(10):
     select = gender_to_style5[x]
     user_dict[R_id][x]+=select
id_list = list(user_dict.keys())
gender_list = []
age_list =[]
married_list=[]
job_list=[]
r_style1_list=[]
r_style2_list=[]
income_list=[]
r_style3_list=[]
r_style4_list=[]
r_style5_list=[]
  or i in range(len(user_dict)):
  gender_list.append(list(user_dict.values())[i][0])
  age_list.append(list(user_dict.values())[i][1])
  married_list.append(list(user_dict.values())[i][2])
  job_list.append(list(user_dict.values())[i][3])
  r_style1_list.append(list(user_dict.values())[i][4])
  r_style2_list.append(list(user_dict.values())[i][5])
  income_list.append(list(user_dict.values())[i][6])
  r_style3_list.append(list(user_dict.values())[i][7])
  r_style4_list.append(list(user_dict.values())[i][8])
  r_style5_list.append(list(user_dict.values())[i][9])
temp_dict={'R_id':id_list, 'r_gender':gender_list, 'age':age_list, 'mar': married_list, 'job': job_list,
           'fancy_normal': r_style1_list,'sexual_unisexual': r_style2_list, 'income':income_list,
           'tranditional_trandy': r_style3_list,'formal_casual': r_style4_list,'active_gentle': r_style5_list}
temp_user = pd.DataFrame(temp_dict)
```

Figure 1. 과정1. raw dataset 추출과 column명 리스트 생성

```
temp_user=temp_user.set_index('R_id')
  r i in range(len(temp_user)):
  if temp_user.loc[id_list[i],'r_gender']==1:
   temp_user.loc[id_list[i],'r_gender']='man'
   temp_user.loc[id_list[i],'r_gender']='woman'
  ages=[0,'20_29','30_39','40_49','50_59']
  temp_user.loc[id_list[i],'age'] = ages[temp_user.loc[id_list[i],'age']]
  if temp_user.loc[id_list[i],'mar']==1:
   temp_user.loc[id_list[i],'mar']='married'
   temp_user.loc[id_list[i],'mar']='not_married'
  jobs=[0,'housewife','tech_profession','service','office','student','etc']
  temp_user.loc[id_list[i],'job']=jobs[temp_user.loc[id_list[i],'job']]
  s1=[0,'fancy','normal']
  temp_user.loc[id_list[i],'fancy_normal']=s1[temp_user.loc[id_list[i],'fancy_normal']]
 s2=[0,'sexual','unisexual']
  temp_user.loc[id_list[i],'sexual_unisexual']=s2[temp_user.loc[id_list[i],'sexual_unisexual']]
  incomes=[0,'_200','200_300','300_400','400_500','500_600','600_']
 temp_user.loc[id_list[i],'income']=incomes[temp_user.loc[id_list[i],'income']]
 s3=[0,'tranditional','trandy']
 temp_user.loc[id_list[i],'tranditional_trandy']=s3[temp_user.loc[id_list[i],'tranditional_trandy']]
 s4=[0,'formal','casual']
 temp_user.loc[id_list[i], 'formal_casual'] = s4[temp_user.loc[id_list[i], 'formal_casual']]
 s5=[0,'active','gentle']
  temp_user.loc[id_list[i], 'active_gentle']=s5[temp_user.loc[id_list[i], 'active_gentle']]
temp_user.to_csv('/content/drive/MyDrive/학부연구생/패션/output_dataset/user_preprocessing_out.csv')
```

Figure 2. 과정2. research dataset으로 부터 정보 추출 및 새로운 dataset 생성

1-2-B. 참가자 dataset 추출 및 가공 결과

| R_id | r_gender | age | mar | job | fancy_norn | sexual_uni | income | tranditional | formal_cas | active_ger |
|------|----------|-------|-------------|------------|------------|------------|---------|--------------|------------|------------|
| 27 | man | 50_59 | not_married | office | fancy | unisexual | 600_ | trandy | casual | active |
| 133 | man | 30_39 | married | etc | normal | sexual | _200 | trandy | casual | gentle |
| 179 | woman | 40_49 | married | office | normal | sexual | 500_600 | tranditional | casual | gentle |
| 289 | woman | 30_39 | not_married | housewife | normal | unisexual | 300_400 | tranditional | casual | active |
| 1022 | woman | 30_39 | married | etc | normal | unisexual | _200 | tranditional | casual | gentle |
| 1027 | woman | 20_29 | married | etc | normal | unisexual | _200 | trandy | casual | gentle |
| 1073 | woman | 30_39 | not_married | housewife | normal | unisexual | 300_400 | trandy | casual | active |
| 1512 | woman | 40_49 | not_married | housewife | normal | unisexual | 500_600 | tranditional | casual | gentle |
| 1513 | woman | 40_49 | not_married | housewife | normal | sexual | _200 | tranditional | casual | gentle |
| 1516 | woman | 40_49 | not_married | housewife | normal | unisexual | 200_300 | trandy | casual | gentle |
| 1880 | woman | 30_39 | married | etc | normal | unisexual | 300_400 | trandy | casual | active |
| 1968 | woman | 50_59 | not_married | tech_profe | normal | unisexual | 200_300 | trandy | casual | gentle |
| 1969 | woman | 50_59 | not_married | service | normal | unisexual | _200 | trandy | casual | gentle |
| 1970 | woman | 40_49 | not_married | housewife | normal | unisexual | 600_ | trandy | casual | active |

Figure 3. 추출한 참가자 dataset (일부 rows, columns)

1-3. research dataset 가공

raw dataset에서 추출 및 가공한 이미지 dataset과 참가자 dataset을 가지고 research dataset을 가 공함으로써 머신러닝 모델을 돌리기 위한 dataset을 만들어 준다.

1-3-A. reserach dataset 가공 코드

```
temp_research = research_dataset.copy()
temp_research=temp_research.drop(['Q1'],axis=1)
columns_list=list(temp_research.columns)
temp_dict = {'season':'','situation':'','fit':'','dark_bright':'','cold_warm':'','heavy_light':'',
             'open':'','useful':'','active':'','comfortable':'','youthful':'','feminine':'','masculine':'','soft':''
rename_list=list(temp_dict.keys())
print(len(rename_list),rename_list)
print(len(columns_list),columns_list)
columns_list=columns_list[5:]
print(len(rename_list),rename_list)
print(len(columns_list),columns_list)
temp_research = temp_research.rename(columns={columns_list[i]: rename_list[i] for i in range(len(rename_list))} )
temp_research.head()
temp_dict={'R_id':id_list, 'r_gender':gender_list, 'age':age_list, 'mar': married_list, 'job': job_list,
            'fancy_normal': r_style1_list,'sexual_unisexual': r_style2_list, 'income':income_list,
            'tranditional_trandy': r_style3_list,'formal_casual': r_style4_list,'active_gentle': r_style5_list}
rename_list=list(temp_dict.keys())
columns_list=list(temp_research.columns)
columns_list=columns_list[33:]
rename_list=rename_list[5:]
temp_research = temp_research.rename(columns={columns_list[i]: rename_list[i] for i in range(len(rename_list))} )
 #research_dataset[6:28]는 image_dataset에 mapping by ImgName
 #research_dataset[29:]은 user_dataset에 mapping by R_id
image_name_list=list(temp_image.index)
image_name_list.pop() #last row -> nan. don't know the reaseon.
image_dict={image_name_list[i]: list(temp_image.loc[image_name_list[i]])[4:] for i in range(len(image_name_list))}
user_id_list=list(temp_user.index)
user_dict={user_id_list[i]: list(temp_user.loc[user_id_list[i]]) for i in range(len(user_id_list))}
```

Figure 4. 과정1. research dataset의 column명에 맞는 리스트 생성 등

```
Q5(선호여부 정보 object화)
  r i in range(len(temp_research)):
  if temp_research.loc[i,'Q5'] == 2:
   temp_research.loc[i,'Q5']='Positive'
  else:
   temp_research.loc[i,'Q5']='Negative'
#img정보 처리
temp_research = temp_research.set_index('imgName')
temp_dict = {'season':'','situation':'','fit':'','dark_bright':'','cold_warm':'','heavy_light':'',
            'open':'','useful':'','active':'','comfortable':'','youthful':'','feminine':'','masculine':'','soft':''}
column_list=list(temp_dict.keys())
for i in range(len(image_name_list)):
  image_name = image_name_list[i]
  for j in range(len(list(image_dict.values())[0])):
   col = column_list[j]
   temp_research.loc[image_name, col]=image_dict[image_name][j]
 user 정보 처리
temp_research = temp_research.set_index('R_id')
temp_dict={'R_id':id_list, 'r_gender':gender_list, 'age':age_list, 'mar': married_list, 'job': job_list,
           'fancy_normal': r_style1_list, 'sexual_unisexual': r_style2_list, 'income':income_list,
           'tranditional_trandy': r_style3_list,'formal_casual': r_style4_list,'active_gentle': r_style5_list}
column_list=list(temp_dict.keys())
column_list.pop(0)
 for i in range(len(user_id_list)):
 user_id = user_id_list[i]
  for j in range(len(list(user_dict.values())[0])):
   col = column_list[j]
   temp_research.loc[user_id, col]=user_dict[user_id][j]
temp_research=temp_research.set_index('E_id')
temp_research.to_csv('/content/drive/MyDrive/학부연구생/패션/output_dataset/research_preprocessing_out.csv')
```

Figure 5. 과정2. 기존의 dataset을 이용하여 새로운 research dataset 생성

1-3-B. research dataset 가공 결과

```
Eld era style gender season struation fit. dark.brig/cold.warm/heavy.light-cool | urban trandy | stylich | heat | fancy | unique | normal | open | useful | active | comfortabyouthful | feminine masculine coff | not_users | fancy | not_users | not
```

Figure 6. 추출한 research dataset (일부 rows, columns)

2. 모델링

전처리된 dataset을 가지고 머신러닝 모델 LogisticRegression, AdaBoostClassifier, GradientBoostingClassifier를 이용하여 각각의 정확도를 확인하였다. 이때 각 model에 해당 dataset을 적용하기 위해 dataset을 그대로 적용하지 않고 one hot encoding 방법으로 적용하였다. 또한, 하이퍼 파라미터를 입력하지 않고 도출된 결과와 하이퍼 파라미터를 튜닝하여 도출된 결과를 비교할 수 있도록 구축하였다.

2-1-A. 모델링 코드

```
import ...
research_dataset = pd.read_csv('/content/drive/MyDrive/학부연구생/패션/output_dataset/research_preprocessing_out.csv')
df = research_dataset.copy()
df = df.set_index('E_id')
 feature와 label 나누기
X = df.drop(['Q5'], axis=1)
y = df['05']
 # one hot encoding
X = pd.get_dummies(X)
 split X and y into traning and testing sets
 rom sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2, random_state = 0)
#모델 종류
  rom sklearn.linear_model import LogisticRegression
   om sklearn.ensemble import AdaBoostClassifier
  rom sklearn.ensemble import GradientBoostingClassifier
 default 학습 결과
before_result = {'logistic':0, 'abc': 0, 'gb': 0}
logistic_model = LogisticRegression()
logistic_model.fit(X_train,y_train)
logistic_y_pred = logistic_model.predict(X_test)
 LogisticRegression Accuracy
print("Logistic Regression Accuracy:", metrics.accuracy_score(y_test, logistic_y_pred))
before_result['logistic']=metrics.accuracy_score(y_test, logistic_y_pred)
abc_model = AdaBoostClassifier()
abc_model.fit(X_train,y_train)
abc_y_pred = abc_model.predict(X_test)
 AdaBoostClassifier Accuracy
print("AdaBoost Classifier Accuracy:", metrics.accuracy_score(y_test, abc_y_pred))
before_result['abc']=metrics.accuracy_score(y_test, abc_y_pred)
gb_model = GradientBoostingClassifier()
 gb_model.fit(X_train, y_train, sample_weight=None, monitor=None)
gb_y_pred = gb_model.predict(X_test)
 GradientBoostingClassifier Accuracy
print("GradientBoosting Classifier Accuracy:",metrics.accuracy_score(y_test, gb_y_pred))
before_result['gb']=metrics.accuracy_score(y_test, gb_y_pred)
```

Figure 1. 과정1. dataset을 로드한 후, 하이퍼파라미터를 적용하지 않고 모델 적용

```
logistic regression 하이퍼파라미터 튜닝용 함수
   f logistic_tuning(X_train, y_train, params):
   #model = LogisticRegression(random_state = 99)
   model = LogisticRegression()
   # 파라미터 튜닝(train data 전체를 넣어서 5-fold cv)
   grid = GridSearchCV(model, params, scoring = 'roc_auc', cv = 5)
   grid.fit(X_train, y_train)
   print(grid.best_params_)
   print(grid.best_score_)
   return grid.best_estimator_
logistic_param = {'C':[(4.0+x/10.0) for x in range(20)], 'max_iter': [150+m for m in range(0,110,10)]}
logistic_tuning_result = logistic_tuning(X_train, y_train, params = logistic_param) #최적의 하이퍼파라미터 확인
 # AdaBoost Classifier 하이퍼파라미터 튜닝용 함수
   f abc_tuning(train_sprs, y, params):
    model = AdaBoostClassifier()
   grid = GridSearchCV(model, params, scoring = 'roc_auc', cv = 5)
   grid.fit(train_sprs, y)
   print(grid.best_params_)
   print(grid.best_score_)
   return grid.best_estimator_
abc_param = {'n_estimators':[50+n for n in range(0,100,10)],'learning_rate':[1.0 + 0.005*i for i in range(1,11)]}
abc_tuning_result = abc_tuning(X_train, y_train, params = abc_param) #최적의 하이퍼파라미터 확인.
 # gradient boosting 하이퍼파라미터 튜닝용 함수
   gb_tuning(train_sprs, y, params):
   model = GradientBoostingClassifier()
   # 파라미터 튜닝(train data 전체를 넣어서 5-fold cv)
   grid = GridSearchCV(model, params, scoring = 'roc_auc', cv = 5)
   grid.fit(train_sprs, y)
   print(grid.best_params_)
   print(grid.best_score_)
   return grid.best_estimator_
gb_param = {'n_estimators': [100+n for n in range(10,100,10)], 'max_depth': [3+m for m in range(1,6)]}
gb_tuning_result = gb_tuning(X_train, y_train, params = gb_param) #최적의 하이퍼파라미터 확인.
```

Figure 2. 과정2. 각각의 머신러닝 모델에 맞게 하이퍼파라미터 튜닝함수 적용

```
#최적의 하이퍼파라미터로 학습한 후 결과
after_result = {'logistic':0, 'abc': 0, 'gb': 0}
#{'C': 5.9, 'max_iter': 250}
logistic_model = LogisticRegression(C=5.9, max_iter=250)
logistic_model.fit(X_train,y_train)
logistic_y_pred = logistic_model.predict(X_test)
# Model Accuracy, how often is the classifier correct?
print("Logistic Regression Accuracy:", metrics.accuracy_score(y_test, logistic_y_pred))
after_result['logistic'] = metrics.accuracy_score(y_test, logistic_y_pred)
 {'learning_rate': 1.05, 'n_estimators': 100}
abc_model = AdaBoostClassifier(learning_rate=1.05, n_estimators=100)
abc_model.fit(X_train,y_train)
abc_y_pred = abc_model.predict(X_test)
print("AdaBoost Classifier Accuracy:",metrics.accuracy_score(y_test, abc_y_pred))
after_result['abc'] = metrics.accuracy_score(y_test, abc_y_pred)
  {'max_depth': 5, 'n_estimators': 190}
gb_model = GradientBoostingClassifier(max_depth=5, n_estimators=190)
gb_model.fit(X_train, y_train, sample_weight=None, monitor=None)
gb_y_pred = gb_model.predict(X_test)
print("GradientBoosting Classifier Accuracy:",metrics.accuracy_score(y_test, gb_y_pred))
after_result['gb'] = metrics.accuracy_score(y_test, gb_y_pred)
```

Figure 3. 과정3. 하이퍼파라미터 튜닝 후의 결과 확인

```
lot of before_result
names = list(before_result.keys())
  r name in names:
 values.append(before_result[name])
plt.figure(figsize=(3, 3))
plt.scatter(names, values)
plt.title('default_result')
 #plt.show()
print(before_result)
plt.savefig('/content/drive/MyDrive/학부연구생/패션/output_image/default_result.png')
plt.close()
#plot of after_result
names = list(after_result.keys())
values=[]
  or name in names:
 values.append(after_result[name])
plt.figure(figsize=(3, 3))
plt.scatter(names, values)
plt.title('tuned_result')
 #plt.show()
print(after_result)
plt.savefig('/content/drive/MyDrive/학부연구생/패션/output_image/tuned_result.png')
plt.close()
  파라미터 확인
 logistic_model.get_params()
abc_model.get_params()
gb_model.get_params()
```

Figure 4. 과정4. 결과를 그래프로 도출

3. 결과

| Model | Default Acc. | Tuned Acc. |
|----------------------------|--------------|------------|
| LogisticRegression | 0.7235209 | 0.7280919 |
| AdaBoostClassifier | 0.7284837 | 0.7287449 |
| GradientBoostingClassifier | 0.7269165 | 0.7403682 |

Table 1. A table caption.

머신러닝모델 LogisticRegression, AdaBoostClassifier, GradientBoostingClassifier에 동일한 dataset을 적용한 결과이다. 먼저, LogisticRegression의 경우 default accuracy는 0.7235209, 튜닝후 accuracy는 0.7280919이다. 하이퍼 파라미터를 튜닝한 결과, 'C': 5.9, 'max_iter': 250이 최적의 파라미터로 확인되었다. 다음으로 AdaBoostClassifier의 경우 default accracy는 0.7284837, 튜닝후 accuracy는 0.7287449이며, 튜닝한최종 하이퍼 파라미터는 'learning_rate': 1.05, 'n_estimators': 100이다. 마찬가지로 GradientBoostingClassifier의 경우도 default accracy는 0.7269165, 튜닝후 accuracy는 0.7403682, 튜닝한최종 하이퍼 파라미터는 'max_depth': 5, 'n_estimators': 190으로 확인할수 있었다.

3-1. 적용된 최적의 파라미터

- LogisticRegression 'C': 5.9, 'class_weight': None, 'dual': False, 'fit_intercept': True, 'intercept_scaling': 1, 'l1_ratio': None, 'max_iter': 250, 'multi_class': 'auto', 'n_jobs': None, 'penalty': 'l2', 'random_state': None, 'solver': 'lbfgs', 'tol': 0.0001, 'verbose': 0, 'warm_start': False
- AdaBoostClassifier 'algorithm': 'SAMME.R', 'base_estimator': None, 'learning_rate': 1.05, 'n_estimators': 100, 'random_state': None
- GradientBoostingClassifier 'ccp_alpha': 0.0, 'criterion': 'friedman_mse', 'init': None, 'learning_rate': 0.1, 'loss': 'deviance', 'max_depth': 5, 'max_features': None, 'max_leaf_nodes': None, 'min_impurity_decrease': 0.0, 'min_samples_leaf': 1, 'min_samples_split': 2, 'min_weight_fraction_leaf': 0.0, 'n_estimators': 190, 'n_iter_no_change': None, 'random_state': None, 'subsample': 1.0, 'tol': 0.0001, 'validation_fraction': 0.1, 'verbose': 0, 'warm_start': False

3-2. 그래프

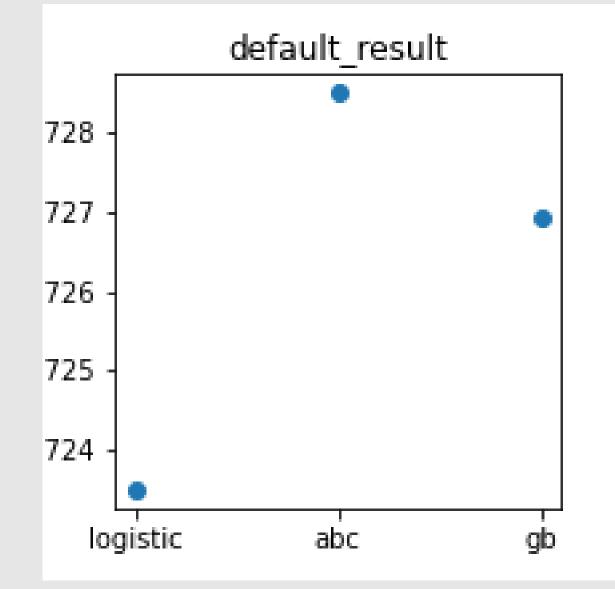


Figure 5. Default Accuracy

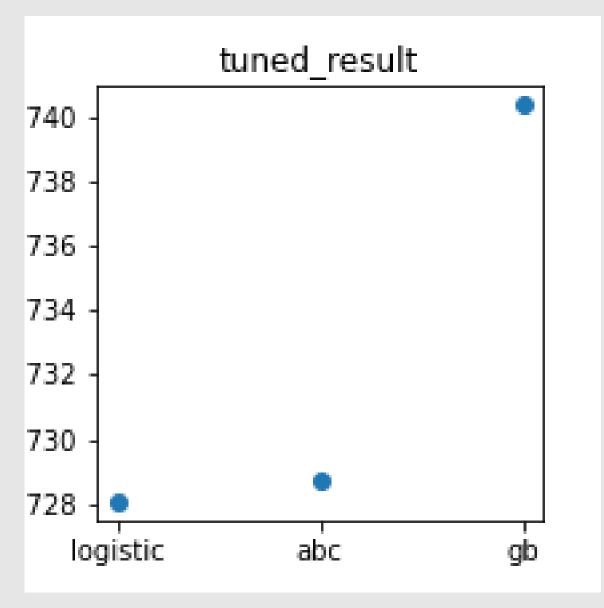


Figure 6. Tuned Accuracy